

ESTIMACIÓN POR MÍNIMOS CUADRADOS ORDINARIOS (MCO)

Econometría I

Prof. William Canales Molina.

Material estrictamente académico

1. METODOLOGÍA DE ESTIMACIÓN MCO

- Dados el modelo de regresión poblacional y el estimado:

$$Y_i = \beta_1 + \beta_2 X_i + u_i$$

$$\hat{Y}_i = \hat{\beta}_1 + \hat{\beta}_2 X_i = b_1 + b_2 X_i$$

se definen los *residuos* de cualquier línea ajustada como:


$$e_i = Y_i - \hat{Y}_i = Y_i - (b_1 + b_2 X_i)$$

- Cada valor observado de la variable endógena puede expresarse como:

$$Y_i = \hat{Y}_i + e_i$$


$$Y_i = b_1 + b_2 X_i + e_i$$

Continuación...




En la práctica sólo observamos los puntos P .

Continuación...




Podemos usar los puntos P para dibujar una línea recta que sea una aproximación de $Y = \beta_1 + \beta_2X$. Esta línea estimada será $Y = b_1 + b_2X$, donde b_1 es un estimador de β_1 y b_2 es un estimador de β_2 .

Continuación...




La línea se llama modelo ajustado y los valores de Y estimados se llaman valores ajustados de Y . Se representan por la altura de los puntos R .

Continuación...




La discrepancia entre el valor observado y el valor ajustado de Y se conoce como residuo.

Continuación...




Importante: Note que el residuo no es igual al término de perturbación.

Continuación...




El término de perturbación en cada observación es el responsable de la divergencia entre el valor observado y el componente no aleatorio de la verdadera relación.

Continuación...




El residuo es la discrepancia entre el valor observado y el valor ajustado de la variable endógena.

Continuación...




Si la regresión es “buena”, los residuos y los valores del término de perturbación serán similares (ver primera y segunda obs.), pero son conceptualmente distintos.


Continuación...




Las dos rectas serán analizadas en el curso. Cada una permite la descomposición del valor de Y . Esta descomposición se ilustrará con la cuarta observación.



Usando la relación teórica, Y puede descomponerse en un componente no estocástico y un componente aleatorio.



Es una descomposición teórica porque desconocemos los valores de β_1, β_2 o los valores del término de perturbación.



La otra descomposición es en referencia a la línea ajustada. En cada observación, el valor observado de Y es igual al valor ajustado de Y más el residuo. Esta es una descomposición operativa que se utilizará para usos prácticos.

Principio de mínimos cuadrados

- El **Principio de Mínimos Cuadrados** consiste en:

$$\underset{b_1, b_2}{\text{Min}} SCR = \sum_{i=1}^n e_i^2 = e_1^2 + \dots + e_n^2$$

- Condiciones de Primer Orden.

$$\frac{\partial \sum_{i=1}^n e_i^2}{\partial b_1} = 0$$

$$\frac{\partial \sum_{i=1}^n e_i^2}{\partial b_2} = 0$$

- Ecuaciones Normales:

$$\sum_{i=1}^n e_i = 0$$

$$\sum_{i=1}^n x_i e_i = 0$$

Condiciones de primer y segundo orden

- Primera condición de primer orden:

$$\frac{\partial SCR}{\partial b_1} = 0 \Rightarrow -2\left(\sum Y_i - b_1 - b_2 X_i\right) = 0$$

$$\sum Y_i - b_1 n - b_2 \sum X_i = 0$$

$$b_1 = \bar{Y} - b_2 \bar{X}$$

$$\bar{X} = \frac{\sum X_i}{n}$$

$$\sum X_i = n\bar{X}$$

- Segunda condición de primer orden:

$$\frac{\partial SCR}{\partial b_2} = 0 \Rightarrow -2\left(\sum Y_i - b_1 - b_2 X_i\right)X_i = 0$$

Metodología de estimación...

$$\frac{\partial SCR}{\partial b_2} = 0 \Rightarrow -2\left(\sum Y_i - b_1 - b_2 X_i\right)X_i = 0$$

$$\sum ((Y_i - b_1 - b_2 X_i)X_i) = 0$$

$$\sum Y_i X_i - b_1 \sum X_i - b_2 \sum X_i^2 = 0$$

$$\sum Y_i X_i - (\bar{Y} - b_2 \bar{X}) \sum X_i - b_2 \sum X_i^2 = 0$$

$$\sum Y_i X_i - \bar{Y} \sum X_i + b_2 \bar{X} \sum X_i - b_2 \sum X_i^2 = 0$$

$$\sum Y_i X_i - n\bar{Y}\bar{X} + b_2 n\bar{X}^2 - b_2 \sum X_i^2 = 0$$

$$b_2 = \frac{\sum Y_i X_i - n\bar{Y}\bar{X}}{\sum X_i^2 - n\bar{X}^2} = \frac{\sum (X_i - \bar{X})(Y_i - \bar{Y})}{\sum (X_i - \bar{X})^2}$$

Continuación...

Demostración de Resultados Importantes:

$$\begin{aligned}\sum (X_i - \bar{X})(Y_i - \bar{Y}) &= \sum X_i Y_i - \sum X_i \bar{Y} - \sum \bar{X} Y_i + \sum \bar{X} \bar{Y} \\ &= \sum X_i Y_i - \bar{Y} \sum X_i - \bar{X} \sum Y_i + n \bar{X} \bar{Y} \\ &= \sum X_i Y_i - \bar{Y} (n \bar{X}) - \bar{X} (n \bar{Y}) + n \bar{X} \bar{Y} \\ &= \sum X_i Y_i - n \bar{X} \bar{Y}\end{aligned}$$

Análogamente:

$$\begin{aligned}\sum (X_i - \bar{X})^2 &= \sum (X_i^2 - 2\bar{X}X_i + \bar{X}^2) = \sum X_i^2 - 2n\bar{X}^2 + n\bar{X}^2 \\ &= \sum X_i^2 - n\bar{X}^2\end{aligned}$$

Continuación...

- Estimador MCO de β_1

$$b_1 = \bar{Y} - b_2 \bar{X}$$

- Estimador MCO de β_2 :

$$SC3: \sum_{i=1}^n (X_i - \bar{X})^2 > 0$$

$$b_2 = \frac{\sum_{i=1}^n (X_i - \bar{X})(Y_i - \bar{Y})}{\sum_{i=1}^n (X_i - \bar{X})^2}$$

$$b_2 = r_{YX} \frac{\sqrt{\sum_{i=1}^n (Y_i - \bar{Y})^2}}{\sqrt{\sum_{i=1}^n (X_i - \bar{X})^2}}$$

- Estos estimadores replican los poblacionales (normalidad):

<i>Poblacional</i>	<i>Muestral</i>
$\beta_{1_{YX}} = \mu_Y - \rho \frac{\sigma_Y}{\sigma_X} \mu_X$	$b_1 = \bar{Y} - b_2 \bar{X}$
$\beta_{2_{YX}} = \rho \frac{\sigma_Y}{\sigma_X}$	$b_2 = r \frac{SE(Y)}{SE(X)}$

Estimador de la varianza

- *Estimador de la varianza del término de perturbación.*
 - No se puede estimar a partir de una muestra de valores de u , pues depende de los parámetros poblacionales no observados β_1 y β_2 .
 - Puede obtenerse un estimado a partir de los errores de estimación. El estimador es:

$$\hat{\sigma}_{MCO}^2 \equiv s^2 = \frac{1}{n-2} \sum_{i=1}^n e_i^2$$

Modelo con K variables

- El modelo de regresión poblacional de “k” variables, para una observación o período de tiempo, se denota por:

$$Y_i = \beta_1 + \beta_2 x_{i2} + \beta_3 x_{i3} + \cdots + \beta_k x_{ik} + u_i$$

$$y = X\beta + u$$

$$\beta = \begin{bmatrix} \beta_1 \\ \vdots \\ \beta_k \end{bmatrix}$$

y el modelo de regresión estimado:

$$\hat{Y}_i = b_1 + b_2 x_{i2} + b_3 x_{i3} + \cdots + b_k x_{ik}$$
$$\hat{Y}_i = \hat{\beta}_1 + \hat{\beta}_2 x_{i2} + \hat{\beta}_3 x_{i3} + \cdots + \hat{\beta}_k x_{ik}$$

Matricialmente

- Matricialmente, para las n observaciones:

$$\begin{matrix} y = X\beta + u \end{matrix} \quad \begin{bmatrix} Y_1 \\ Y_2 \\ \vdots \\ Y_n \end{bmatrix}_{(n \times 1)} = \begin{bmatrix} X_{11} & X_{12} & \cdots & X_{1k} \\ X_{21} & X_{22} & \cdots & X_{2k} \\ \vdots & \vdots & \ddots & \vdots \\ X_{n1} & X_{n2} & \cdots & X_{nk} \end{bmatrix}_{(n \times k)} \begin{bmatrix} \beta_1 \\ \beta_2 \\ \vdots \\ \beta_k \end{bmatrix}_{(k \times 1)} + \begin{bmatrix} u_1 \\ u_2 \\ \vdots \\ u_n \end{bmatrix}_{(n \times 1)}$$

- Entonces, dado $\hat{y} = Xb$, se tiene:

$$y = \hat{y} + e = Xb + e$$

Continuación...

- Suma de los cuadrados de los **residuos** o **errores de estimación**:

$$SCR(b) \equiv \sum_{i=1}^n e_i^2 = e'e = (y - \hat{y})'(y - \hat{y})$$

$$SCR(b) \equiv y'y - 2b'X'y + b'X'Xb$$

$$SCR(b) \equiv y'y - 2y'Xb + b'X'Xb$$

- De acuerdo al **Principio de Mínimos Cuadrados Ordinarios**, se **minimiza SCR**, lo cual implica que se cumpla las C.P.O. y C.S.O:

Continuación...

$$\frac{\partial SCR}{\partial b} = 0 \Rightarrow (X'X)b = X'y$$

$$\frac{\partial^2 SCR}{\partial b \partial b'} = 2X'X \quad \text{positivo definida}$$

Reglas de derivación de matrices

$$\frac{\partial(a'x)}{\partial x} = a; \quad \frac{\partial(Ax)}{\partial x} = A';$$

$$\frac{\partial(x'Ax)}{\partial x} = 2(x'A)' = 2Ax, \quad A: \text{matriz simétrica}$$

$$\frac{\partial(x'Ax)}{\partial A} = x'x, \quad x'x: \text{matriz cuadrada}$$

- Las **Ecuaciones Normales** se obtienen a partir de las Condiciones de Primer Orden (C.P.O.):

$$(X'X)b = X'y$$

$$\Rightarrow X'e = 0$$

Continuación...

- En el modelo de regresión lineal clásico de k variables se obtiene k ecuaciones normales: una para cada parámetro especificado en la ecuación de regresión.
- A partir de la CPO se obtiene el vector de ***estimadores de MCO del MRLCK***:

$$b = \hat{\beta}_{MCO} = (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'y$$

- Supuesto de “rango completo por columnas” es importante! Para derivar el estimador MCO sólo se necesita que $\mathbf{X}'\mathbf{X}$ tenga inversa y ello se cumple **sólo si se cumple el SC 3**.

Continuación...

Estimador de la Varianza s^2 .

- Es razonable obtener el estimador a partir de la suma de cuadrados de los residuos:

$$e = y - Xb$$

$$e = y - \mathbf{X}(\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'y$$

$$e = (\mathbf{I}_n - \mathbf{X}(\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}')y$$

$$e = \mathbf{M}y$$

- Donde \mathbf{M} es una matriz *simétrica* e *idempotente*; además:

$$\mathbf{M}' = \mathbf{M}; \quad \mathbf{M} = \mathbf{M}^2$$

$$\mathbf{M}e = e$$

$$\mathbf{M}\mathbf{X} = 0$$

Continuación...

- Con estas propiedades, se tiene que:

$$\begin{aligned} \mathbf{e} &= \mathbf{M}\mathbf{y} = \mathbf{M}(\mathbf{X}\boldsymbol{\beta} + \mathbf{u}) = \mathbf{M}\mathbf{X}\boldsymbol{\beta} + \mathbf{M}\mathbf{u} \\ \mathbf{e} &= \mathbf{M}\mathbf{u} \end{aligned}$$

- Elevando al cuadrado los residuos:

$$\begin{aligned} \mathbf{e}'\mathbf{e} &= (\mathbf{M}\mathbf{u})'\mathbf{M}\mathbf{u} = \mathbf{u}'\mathbf{M}'\mathbf{M}\mathbf{u} \\ \mathbf{e}'\mathbf{e} &= \mathbf{u}'\mathbf{M}\mathbf{u} \end{aligned}$$

- Aplicando la esperanza matemática a esta expresión y aprovechando las propiedades de la traza obtenemos:

Continuación...

$e = Mu$ (Definición del residuo del modelo multivariado.

$$E(e'e) = E((Mu)'Mu)$$

$$E(e'e) = E(u'M'Mu)$$

$$E(e'e) = E(u'Mu) \text{ (} M \text{ es simétrica e idempotente)}$$

$$E(e'e) = E[tr(u'Mu)] \text{ (un escalar es igual a su traza).}$$

$$E(e'e) = E[tr(uu'M)] = E[tr(Muu')] \text{ (propiedades del operador traza)}$$

$$E(e'e) = tr [E(Muu')] \text{ (linealidad del operador traza)}$$

$$E(e'e) = tr [ME(uu')] \text{ (SC4f)}$$

$$E(e'e) = tr [M\sigma_u^2 I] \text{ (SC5)}$$

$$E(e'e) = \sigma_u^2 tr [M]$$

$$E(e'e) = \sigma_u^2(n - k) \text{ (propiedad de la matriz } M)$$

$$E\left(\frac{e'e}{n - k}\right) = \sigma_u^2$$

Continuación...

$$E(\mathbf{e}'\mathbf{e}) = \sigma_u^2(n-k)$$

$$E\left(\frac{\mathbf{e}'\mathbf{e}}{n-k}\right) = \sigma_u^2$$

- Así, el estimador de la varianza del término de perturbación, y de la regresión, es:

$$s^2 \equiv \hat{\sigma}_u^2 = \frac{\mathbf{e}'\mathbf{e}}{n-k}$$

- El **error estándar de la estimación** o **error estándar de la regresión**, s , es la desviación estándar de los valores de Y alrededor del plano de regresión.

Características muestrales

- Características asociadas a un modelo bivariado:
 - La línea de regresión estimada pasa por los valores medios muestrales de las variables. $\bar{Y} = b_1 + b_2 \bar{X}$
 - El promedio observado es igual al promedio estimado: $\bar{Y} = \hat{\bar{Y}}$
 - Los *residuos* de MCO tienen correlación cero con la variable independiente (en la muestra). $Corr(X, e) = 0$
 - No existe correlación muestral entre los valores estimados de la variable endógena y los residuos. $Corr(\hat{y}, e) = 0$

Características muestrales de MCO

- Para el modelo de regresión clásico de k variables:
 - La ecuación de regresión o hiperplano de regresión pasa por los **puntos medios** del espacio “k” dimensional.

$$\bar{Y} = b_1 + b_2 \bar{X}_2 + b_3 \bar{X}_3 + \cdots + b_k \bar{X}_k \quad \longrightarrow \quad \bar{y} = \bar{X}b$$

- El promedio observado es igual al promedio estimado: $i' y = i' \hat{y}$
- La correlación muestral de los regresores con los residuos es cero. $X'e = 0$
- Los valores estimados de la variable dependiente no están correlacionados con los residuos. $\hat{y}' e = 0$

Estimación de MCO como proyección

- **M** es la Matriz Generadora de Residuos: $My = e$
 - **M** ($n \times n$), simétrica, idempotente, $\dim(M) = \text{tr}(M)$.
 - **M** es la Matriz Aniquiladora: la proyección de X sobre X es perfecta y el residuo es cero. $MX = 0$
- **P** es la **Matriz de Proyección** sobre el espacio columna **X**

$$\hat{y} = Xb = Py$$

- **P** ($n \times n$), simétrica, idempotente, $\dim(P) = \text{tr}(P)$.
- La proyección de X sobre X es igual a X : $PX = X$

Continuación...

- Además, $PM = MP = 0$.
- Entonces, la estimación por MCO particiona y en dos componentes ortogonales:

$$y = \hat{y} + e$$

$$y = Py + My$$

- ***Teorema de Pitágoras: Suma de Cuadrados***


$$y' y = \hat{y}' \hat{y} + e' e$$

Geometría de MCO


- Geometría de MCO:




- Geometría de MCO:




- Geometría de MCO:




- Geometría de MCO:




- Geometría de MCO:



- Geometría de MCO:




- Geometría de MCO:



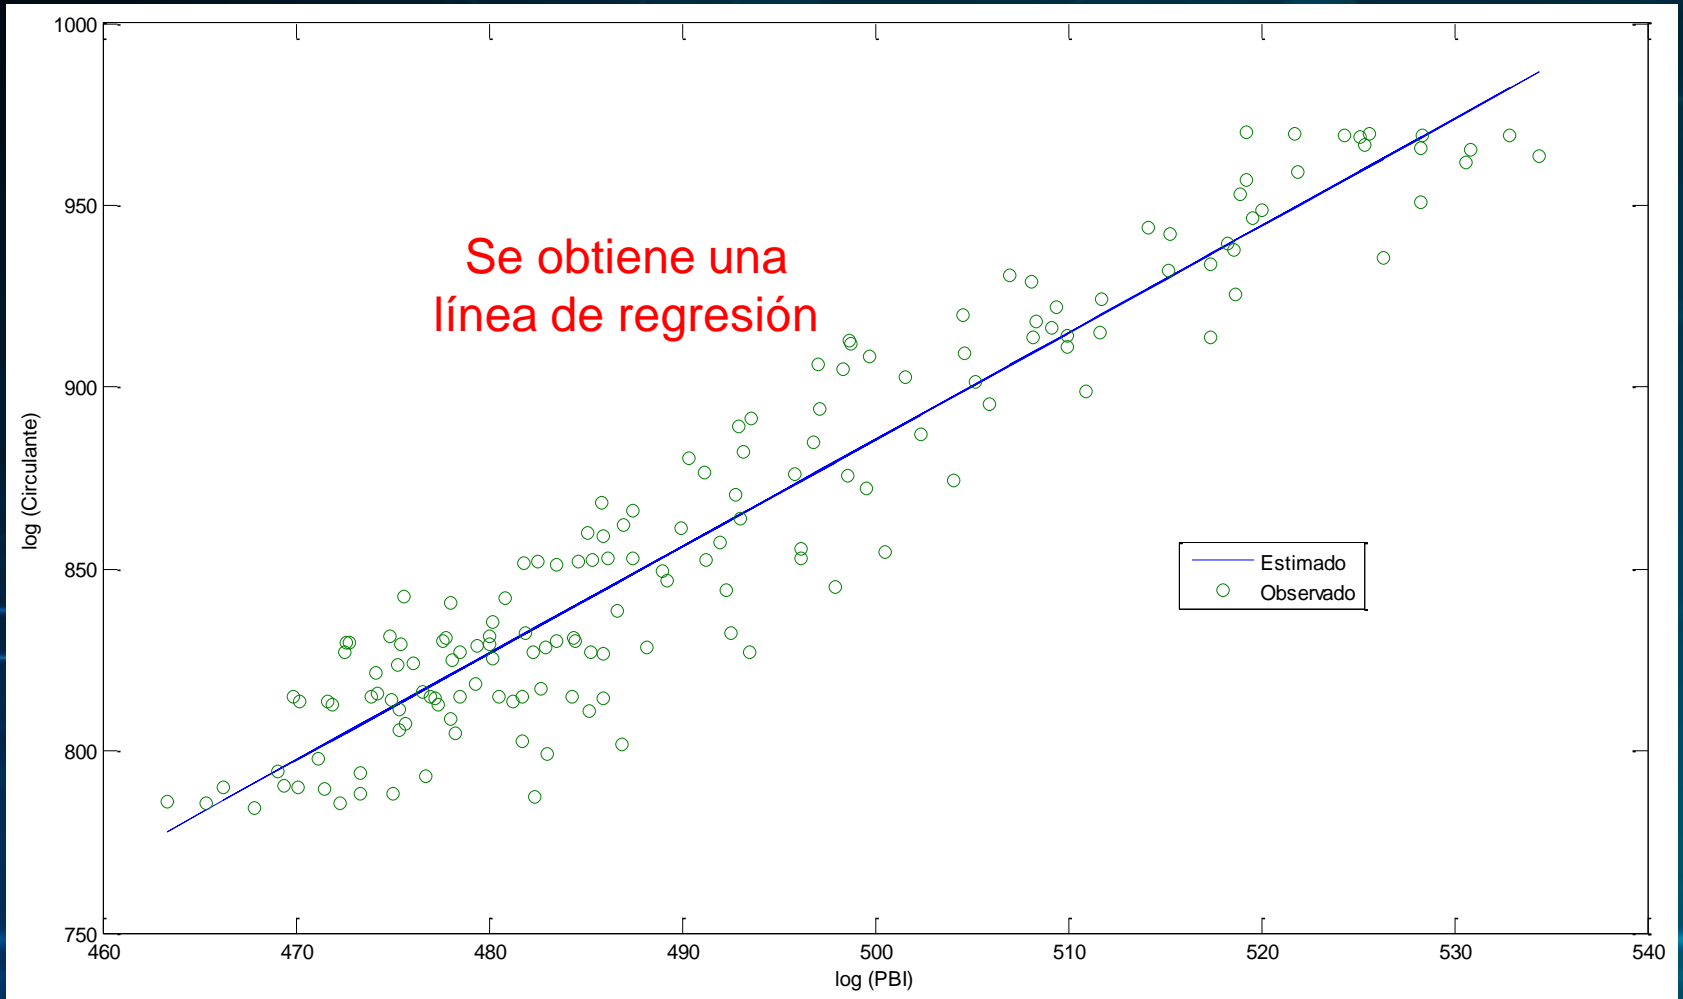
Estimación como proyección

- Geometría de MCO:



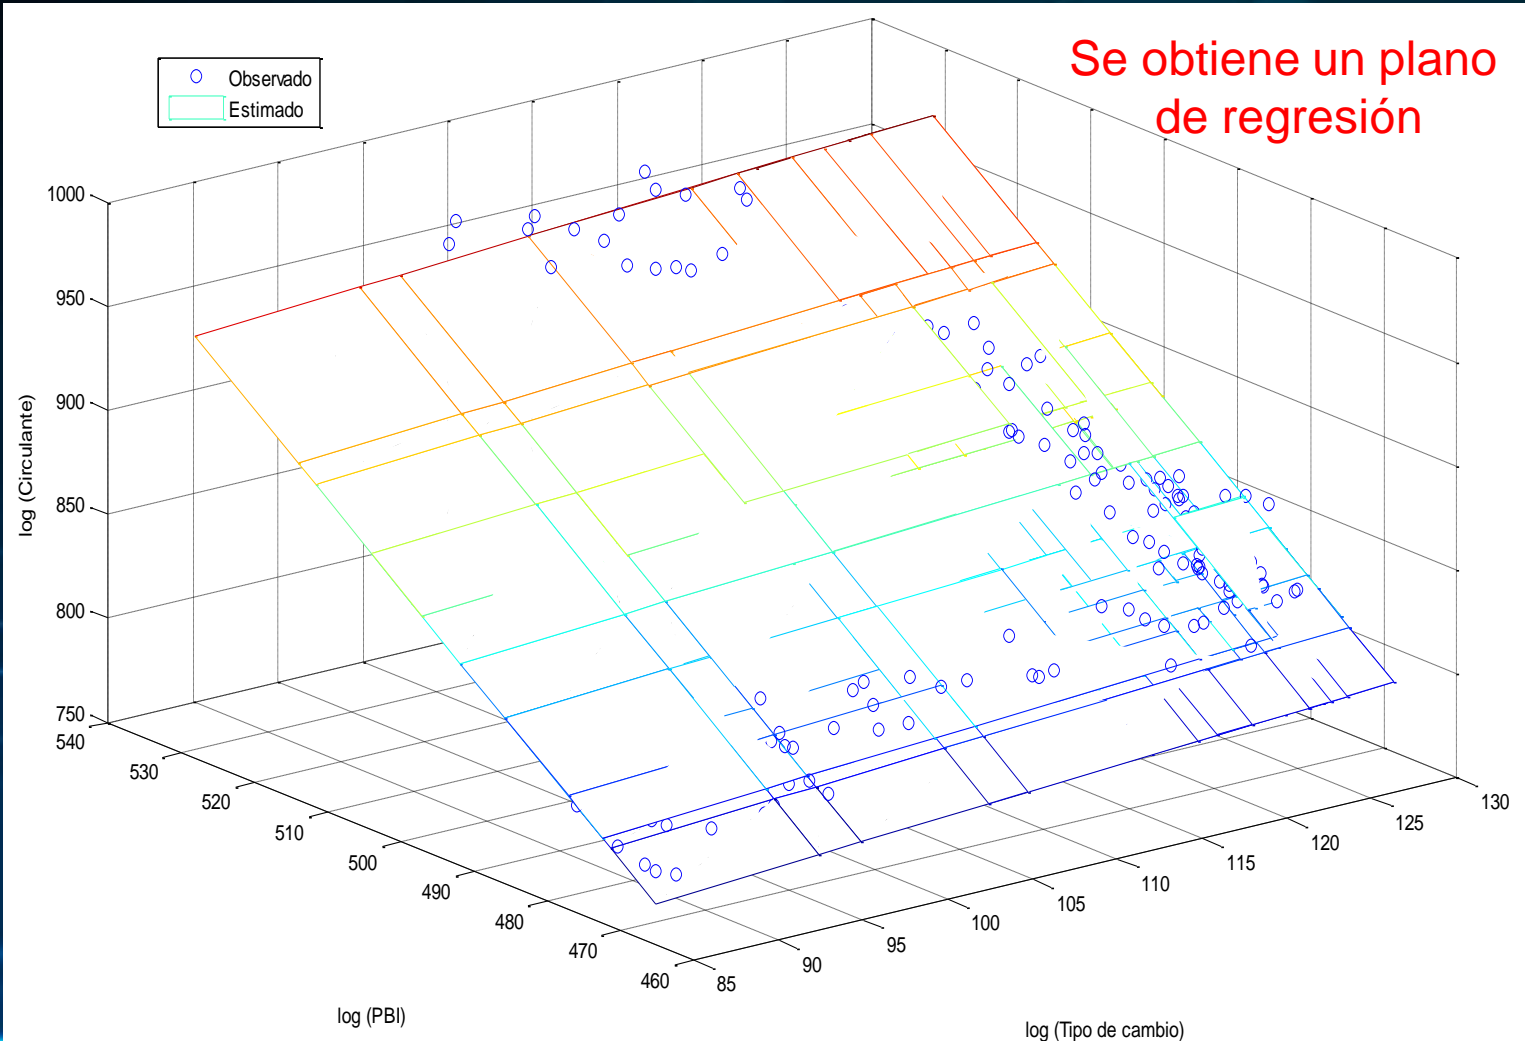
Continuación...

- A través del uso de matrices : caso de dos variables




Continuación...

- A través del uso de matrices : caso de tres variables



APLICACIÓN: Estimación del salario por hora



Earnings: salario por hora
S: años de educación

Mayores observaciones para educación básica y secundaria. Pocas observaciones para mayores años de estudio en la muestra analizada.

APLICACIÓN: Estimación del salario por hora

Dependent Variable: EARNINGS

Method: Least Squares

Date: 07/31/11 Time: 22:59

Sample: 1 540

Included observations: 540

Variable	Coefficient	Std. Error	t-Statistic	Prob.
C	-19.79196	3.585928	-5.519341	0.0000
S	2.870943	0.255034	11.25710	0.0000
R-squared	0.190639	Mean dependent var		19.93339
Adjusted R-squared	0.189135	S.D. dependent var		16.43569
S.E. of regression	14.80002	Akaike info criterion		8.230831
Sum squared resid	117843.8	Schwarz criterion		8.246725
Log likelihood	-2220.324	F-statistic		126.7222
Durbin-Watson stat	1.885753	Prob(F-statistic)		0.000000

Continuación...

Dependent Variable: EARNINGS

Method: Least Squares

Date: 07/31/11 Time: 22:59

Sample: 1 540

Included observations: 540

$$EARNINGS = -19.79 + 2.87S$$

Variable	Coefficient	Std. Error	t-Statistic	Prob.
C	-19.79196	3.585928	-5.519341	0.0000
S	2.870943	0.255034	11.25710	0.0000

R-squared	0.190639	Mean dependent var	19.93339
Adjusted R-squared	0.189135	S.D. dependent var	16.43569
S.E. of regression	14.80002	Akaike info criterion	8.230831
Sum squared resid	117843.8	Schwarz criterion	8.246725
Log likelihood	-2220.324	F-statistic	126.7222
Durbin-Watson stat	1.885753	Prob(F-statistic)	0.000000