



ECONOMETRÍA 1: PRÁCTICA DIRIGIDA 4

Curso: Econometría 1
Profesor: Gabriel Rodríguez (gabriel.rodriguez@pucp.edu.pe)
Jefe de práctica: Patricia Lengua Lafosse (patricia.lengua@pucp.pe)

1 Conceptos

1. Función Score
2. Matriz Hessiana
3. Matriz de información de Fisher?
4. Desigualdad de Cramer-Rao y frontera de Cramer-Rao
5. Algoritmo Newton-Raphson

2 Estimación por Máxima Verosimilitud

1. Se tiene el siguiente modelo de regresión multivariado:

$$\begin{aligned} \mathbf{Y} &= \mathbf{X}\beta + \epsilon \\ \epsilon_t &\sim N(0, \sigma^2) \end{aligned}$$

Encontrar el estimador de β y σ^2 por el método de Máxima Verosimilitud.

2. Considere una muestra aleatoria y_1, y_2, \dots, y_T de T observaciones de una distribución Gamma (α, β) con función de densidad:

$$f(y_t | \alpha, \beta) = \frac{\beta^\alpha}{\Gamma(\alpha)} y_t^{\alpha-1} \cdot e^{-\beta y_t} \quad \text{con } t = 1, \dots, T.$$

Hallar los estimadores de Máxima Verosimilitud de α y β .

3. Dado el modelo de regresión multivariado:

$$\begin{aligned} \mathbf{Y} &= \mathbf{X}\beta + \epsilon \\ \epsilon_t &\sim N(0, \sigma^2) \end{aligned}$$

Se tiene que $\hat{\beta}_{MV}$ y $\hat{\sigma}_{MV}^2$ son los estimadores de Máxima Verosimilitud de β y σ^2 . Estimar la varianza asintótica de $\hat{\beta}_{MV}$ y $\hat{\sigma}_{MV}^2$. Además, encuentre la cota inferior de Cramer-Rao de $\hat{\beta}_{MV}$ y $\hat{\sigma}_{MV}^2$ e interprete.

3 Variables Dummy

1. Se cuenta con una muestra de profesionales y se propone el siguiente modelo:

$$\text{ingreso}_i = \beta_0 + \beta_1 \text{mujer}_i + \beta_2 \text{notas}_i + \epsilon_i, \quad i = 1, 2, \dots, N$$

donde ingreso_i es el ingreso por hora en soles, mujer_i es una variable dummy que toma el valor de 1 si es mujer y 0 en otro caso y notas_i es la nota promedio obtenida en estudios superiores.

- (a) Plantee la hipótesis nula para la relevancia del género para explicar el ingreso del individuo.
 (b) Suponga el siguiente modelo alternativo:

$$\text{ingreso}_i = \alpha_0 \text{Hombre}_i + \alpha_1 \text{mujer}_i + \alpha_2 \text{notas}_i + u_i$$

hombre $\begin{cases} 1 & \text{si es hombre} \\ 0 & \text{si es otro} \end{cases}$

Plantee la hipótesis nula para la relevancia del género para explicar el ingreso del individuo. ¿Es posible estimar este modelo?

- (c) Si se desea permitir que el efecto de las notas sobre el ingreso sea distinto para hombres y mujeres, plantee el modelo adecuado. Interprete los coeficientes e ilustre gráficamente el modelo. Además, plantee la hipótesis nula para la relevancia del género.
 (d) Si ahora en lugar de tomar en cuenta las notas, se desea tomar en cuenta la profesión utilizando la variable: $\text{doctor} = 1, 0$ en otro caso. Plantee el modelo adecuado, donde las variables mujer y doctor tengan efectos aditivos y multiplicativos. Interprete los coeficientes e ilustre gráficamente el modelo. Además, plantee la hipótesis nula para la relevancia del género y aquella para la relevancia de la profesión.
 (e) Plantee el modelo que incluya las variables mujer , notas y doctor ; y que además permita que el efecto del género varíe según profesión, así como que el efecto de las notas varíe según género y según profesión. Además, plantee la hipótesis nula para la relevancia del género.
 (f) Suponga que se cuenta con dos variables adicionales: abogado y profesor . Si la muestra está compuesta sólo por doctores, abogados y profesores, responda:
 (i) ¿Es posible estimar el siguiente modelo? Justifique su respuesta.

$$\text{ingreso}_i = \beta_0 + \beta_1 \text{mujer}_i + \beta_2 \text{doctor}_i + \beta_3 \text{abogado}_i + \beta_4 \text{profesor}_i + \beta_5 \text{notas}_i + \epsilon_i$$

- (ii) Interprete los coeficientes de los siguientes modelos alternativos:

$$- \text{ingreso}_i = \beta_0 + \beta_1 \text{mujer}_i + \beta_2 \text{doctor}_i + \beta_3 \text{abogado}_i + \beta_4 \text{notas}_i + \epsilon_i$$

$$- \text{ingreso}_i = \beta_0 + \beta_1 \text{mujer}_i + \beta_2 \text{doctor}_i + \beta_3 \text{profesor}_i + \beta_4 \text{notas}_i + \epsilon_i$$

$$- \text{ingreso}_i = \beta_0 + \beta_1 \text{mujer}_i + \beta_2 \text{abogado}_i + \beta_3 \text{profesor}_i + \beta_4 \text{notas}_i + \epsilon_i$$

Practica Dirigida 4

1. Estimación por Máxima Verosimilitud.

$$1. \quad Y = X\beta + \epsilon \quad \epsilon \sim N(0, \sigma^2)$$

o) Función de verosimilitud.

$$\mathcal{L}(\beta, \sigma^2 | y) = p(y | \beta, \sigma^2) = (2\pi\sigma^2)^{-T/2} \cdot \exp \left\{ -\frac{1}{2\sigma^2} (Y - X\beta)' (Y - X\beta) \right\}$$

$$\ln(\mathcal{L}) = -\frac{T}{2} \log(\sigma^2) - \frac{T}{2} \log(2\pi) - \frac{1}{2\sigma^2} (Y - X\beta)' (Y - X\beta)$$

$$\ln = -\frac{T}{2} \log(\sigma^2) - \frac{T}{2} \log(2\pi) - \frac{1}{2\sigma^2} (Y'Y - 2\beta'X'Y + \beta'X'X\beta)$$

CPO

$$\Rightarrow \frac{\partial \ln}{\partial \beta} = -\frac{1}{2\sigma^2} [-2X'Y + 2X'X\hat{\beta}] = 0 \quad \Rightarrow \quad \hat{\beta}_{MV} = (X'X)^{-1} (X'Y)$$

$$\Rightarrow \frac{\partial \ln}{\partial \sigma^2} = -\frac{T}{2} \frac{1}{\sigma^2} + \frac{1}{2(\sigma^2)^2} (Y - X\hat{\beta}_{MV})' (Y - X\hat{\beta}_{MV}) = 0 \quad \Rightarrow \quad \hat{\sigma}_{MV}^2 = \frac{(Y - X\hat{\beta}_{MV})' (Y - X\hat{\beta}_{MV})}{T}$$

2.

$$f(y_t | \alpha, \beta) = \left[\frac{\beta^\alpha}{\Gamma(\alpha)} \cdot y_t^{\alpha-1} \cdot e^{-\beta y_t} \right] \quad \text{con } t = 1, \dots, T$$

Función Verosimilitud: $\mathcal{L}(\alpha, \beta) = \prod_{t=1}^T f(y_t | \alpha, \beta) = \prod_{t=1}^T \left[\frac{\beta^\alpha}{\Gamma(\alpha)} \cdot y_t^{\alpha-1} \cdot e^{-\beta y_t} \right]$

$$\mathcal{L} = \frac{\beta^\alpha}{\Gamma(\alpha)} \cdot (y_1^{\alpha-1} \cdot e^{-\beta y_1}) \cdot \left(\frac{\beta^\alpha}{\Gamma(\alpha)} \cdot y_2^{\alpha-1} \cdot e^{-\beta y_2} \right) \cdot \dots \cdot \left(\frac{\beta^\alpha}{\Gamma(\alpha)} \cdot y_T^{\alpha-1} \cdot e^{-\beta y_T} \right) = \left[\frac{\beta^\alpha}{\Gamma(\alpha)} \right]^T \cdot e^{-\beta \sum y_t} \cdot \prod_{t=1}^T y_t^{\alpha-1}$$

$$\ln = \ln(\mathcal{L} | y) = T\alpha \ln(\beta) - T \ln(\Gamma(\alpha)) - \beta \sum y_t + (\alpha-1) \sum \ln(y_t)$$

CPO

$$\Rightarrow \frac{\partial \ln}{\partial \beta} = \frac{\alpha T}{\beta} - \sum_{t=1}^T y_t = 0 \quad \Rightarrow \quad \hat{\beta}_{MV} = \frac{\hat{\alpha}_{MV}}{\bar{y}} \quad (i)$$

$$\Rightarrow \frac{\partial \ln}{\partial \alpha} = T \ln \beta - T \cdot \frac{\partial \ln(\Gamma(\alpha))}{\partial \alpha} + \sum_{t=1}^T \ln y_t = 0$$

usamos la primera ecuación (i)

$$T \cdot \ln(\alpha) - T \cdot \ln(\bar{y}) - T \psi(\alpha) + \sum \ln(y_t) = 0 \quad ; \quad \text{con: } \psi(\alpha) = \frac{\partial \ln \Gamma(\alpha)}{\partial \alpha} \quad \text{Fu. digon}$$

I. CONCEPTOS:

1. Función Score: Gradiente de la función de log-verosimilitud (vector de derivadas parciales)

$$\text{Score} = g(\underline{\theta}) = \begin{bmatrix} \frac{\partial l(\underline{\theta})}{\partial \theta_1} \\ \frac{\partial l(\underline{\theta})}{\partial \theta_2} \\ \vdots \\ \frac{\partial l(\underline{\theta})}{\partial \theta_p} \end{bmatrix}_{p \times 1}$$

2. Matriz Hessiana: Matriz de segundas derivadas de la función de log-verosimilitud

$$H(\underline{\theta}) = \begin{bmatrix} \frac{\partial^2 l(\underline{\theta})}{\partial \theta_1^2} & \frac{\partial^2 l(\underline{\theta})}{\partial \theta_1 \partial \theta_2} & \dots & \frac{\partial^2 l(\underline{\theta})}{\partial \theta_1 \partial \theta_p} \\ \frac{\partial^2 l(\underline{\theta})}{\partial \theta_2 \partial \theta_1} & \frac{\partial^2 l(\underline{\theta})}{\partial \theta_2^2} & \dots & \frac{\partial^2 l(\underline{\theta})}{\partial \theta_2 \partial \theta_p} \\ \vdots & \vdots & \ddots & \vdots \\ \frac{\partial^2 l(\underline{\theta})}{\partial \theta_p \partial \theta_1} & \frac{\partial^2 l(\underline{\theta})}{\partial \theta_p \partial \theta_2} & \dots & \frac{\partial^2 l(\underline{\theta})}{\partial \theta_p^2} \end{bmatrix}$$

3. Matriz de Información de Fisher

$$I_F(\underline{\theta}) = -E[H(\underline{\theta})]$$

5) Algoritmo Newton-Raphson.

a) Caso con un parámetro:

$$\text{Func. Score} = g(\theta) = \frac{\partial l(\theta)}{\partial \theta} \quad \left\{ \begin{array}{l} \text{El objetivo es encontrar el valor de } \theta \text{ que} \\ \text{haga que la "función score" sea igual a cero.} \\ g(\theta) = 0 \end{array} \right.$$

Si " θ^* " es una solución y se cumple que: $\left| \frac{\partial g(\theta)}{\partial \theta} \right|_{\theta=\theta^*} < 0$
Entonces, θ^* es un máximo local; si es el único, será el global.

⇒ Consideremos la expansión de Taylor de $g(\theta)$ en torno al punto θ_0

$$g(\theta) \approx g(\theta_0) + g'(\theta_0) \cdot [\theta - \theta_0]$$

Consideramos

Evaluando la expansión en $\theta = \theta^*$ se trae que:

$$\boxed{\theta^* = \theta_0 - \frac{g(\theta_0)}{g'(\theta_0)}}$$

$$\underbrace{g(\theta^*)}_0 \approx g(\theta_0) + g'(\theta_0) \cdot [\theta^* - \theta_0]$$

que induce al siguiente algoritmo:

$$\theta_1 = \theta_0 - \frac{g(\theta_0)}{g'(\theta_0)} \rightsquigarrow$$

$$\theta_j = \theta_{j-1} - \frac{g(\theta_{j-1})}{g'(\theta_{j-1})} \rightsquigarrow$$

* y el algoritmo continuará hasta que

$$\left| \frac{\theta_j - \theta_{j-1}}{\theta_{j-1}} \right| < \epsilon$$

$$\begin{bmatrix} \hat{\beta}_{MV} \\ \hat{\sigma}^2_{MV} \end{bmatrix} = \begin{bmatrix} \frac{1}{\sigma^2} (X'X) & 0 \\ 0 & T/\sigma^4 \end{bmatrix}^{-1} = \begin{bmatrix} \sigma^2 (X'X)^{-1} & 0 \\ 0 & \sigma^4/T \end{bmatrix}$$

* Sabemos que la cota inferior de Cramer Rao de $\hat{\beta}_{MV}$ y $\hat{\sigma}^2$ esta dada por $[I_F(\beta, \sigma^2)]^{-1}$
 Los estimadores de MV tienen la menor varianza dentro de la clase de estimadores consistentes y asintóticamente normales. Incluso se llega a tener varianzas menores a MCO.

Ejemp: $\text{var}(\hat{\sigma}^2_{MV}) < \text{var}(S^2) \Rightarrow \frac{2\sigma^4}{T} < \frac{2\sigma^4}{T-k}$

III. VARIABLES DUMMY

$$\text{ingreso}_i = \beta_0 + \beta_1 \text{mujer}_i + \beta_2 \text{notas}_i + \epsilon_i \quad i=1, 2, \dots, N$$

1. Ho de relevancia de genero: $H_0 \Rightarrow \beta_1 = 0$
 $H_1: \beta_1 \neq 0$

2. Si: $\text{ingreso}_i = \alpha_0 \text{Hombre}_i + \alpha_1 \text{mujer}_i + \alpha_2 \text{notas}_i + u_i$

$$Y = \begin{bmatrix} \text{ingreso}_1 \\ \text{ingreso}_2 \\ \vdots \\ \text{ingreso}_N \end{bmatrix} \quad X = \begin{bmatrix} 1 & 0 & \text{notas}_1 \\ 1 & 0 & \text{notas}_2 \\ \vdots & \vdots & \vdots \\ 1 & 0 & \text{notas}_N \\ 0 & 1 & \vdots \end{bmatrix}$$

$$Y_i = \beta_0 + \alpha_1 \text{hombre}_i + \alpha_2 \text{mujer}_i + \alpha_3 \text{notas}_i + u_i$$

$$X = \begin{bmatrix} 1 & 1 & 0 & \text{notas}_1 \\ 1 & 1 & 0 & \text{notas}_2 \\ \vdots & \vdots & \vdots & \vdots \\ 1 & 1 & 0 & \text{notas}_N \\ 1 & 0 & 1 & \vdots \end{bmatrix}$$

* Si sumamos las columnas de hombre y mujer obtenemos la columna del intercepto
 → Multicolinealidad


⇒ Ho para relevancia de genero: $H_0: \alpha_0 = \alpha_1 = 0$
 $H_1: \alpha_0 \neq 0 \vee \alpha_1 \neq 0$

3. Modelo Inicial: $\text{ingreso}_i = \beta_0 + \beta_1 \text{mujer}_i + \beta_2 \text{notas}_i + \epsilon_i$

Interpretación:

$$E[\text{ingreso} | \text{mujer}=1, \text{notas}] = (\beta_0 + \beta_1) + \beta_2 \text{notas}$$

$$E[\text{ingreso} | \text{mujer}=0, \text{notas}] = \beta_0 + \beta_2 \text{notas}$$




a) Modelo con influencia en notas: $\text{ingreso}_i = \beta_0 + \beta_1 \text{mujer}_i + \beta_2 \text{notas}_i + \beta_3 \text{notas}_i \text{mujer}_i + \epsilon_i$

Interpretación

$$E[\text{ingreso} | \text{mujer}=1, \text{notas}] = (\beta_0 + \beta_1) + (\beta_2 + \beta_3) \text{notas}$$

$$E[\text{ingreso} | \text{mujer}=0, \text{notas}] = \beta_0 + \beta_2 \text{notas}$$



4.) Desigualdad de Cramér-Rao Sea $\underline{Y} = (y_1, y_2, \dots, y_T)$ un vector de var aleatorios (no necesariamente independientes). La función de densidad conjunta es por $f(\underline{Y}; \underline{\theta})$ donde $\underline{\theta}$ es un vector p -dimensional de parámetros, esto es:

$$(\underline{\theta}) = (\theta_1, \theta_2, \dots, \theta_p).$$

Sea $L(\underline{\theta}|\underline{Y})$ la función de verosimilitud y sea $\hat{\theta}(\underline{Y})$ un estimador insesgado de θ con Matriz de varianzas-covarianzas finita. Entonces, bajo ciertas condiciones de regularidad en $f(\underline{Y}; \underline{\theta})$

II. 3. $Y = X\beta + \epsilon \quad \epsilon_i \sim N(0, \sigma^2)$

Teniendo en cuenta la propiedad de normalidad asintótica de los estimadores MV.

$$\begin{bmatrix} \hat{\beta}_{MV} \\ \hat{\sigma}_{MV}^2 \end{bmatrix} \sim N \left[\begin{pmatrix} \beta \\ \sigma^2 \end{pmatrix}, I_F^{-1}(\beta, \sigma^2) \right]$$

* Calculando las segundas derivadas de l .

$$1) \frac{\partial l}{\partial \beta \partial \beta'} = -\frac{1}{\sigma^2} [X'X]$$

$$2) \frac{\partial l}{\partial \beta \partial \sigma^2} = \frac{1}{2(\sigma^2)^2} [-2X'y + 2X'X\beta] = -\frac{1}{(\sigma^2)^2} X' [y - X\beta] = -\frac{1}{(\sigma^2)^2} X' \epsilon$$

$$3) \frac{\partial l}{\partial (\sigma^2)^2} = \frac{T}{2} \cdot \frac{1}{(\sigma^2)^2} - \frac{1}{(\sigma^2)^3} (y - X\beta)'(y - X\beta) = \frac{T}{2} \cdot \frac{1}{(\sigma^2)^2} - \frac{1}{(\sigma^2)^3} \epsilon' \epsilon$$

* Tomando $-E[\cdot]$:

$$1) -E \left[\frac{\partial l}{\partial \beta \partial \beta'} \right] = \frac{1}{\sigma^2} [X'X]$$

$$2) -E \left[\frac{\partial l}{\partial \beta \partial \sigma^2} \right] = -E \left[\frac{T}{2} \frac{1}{(\sigma^2)^2} - \frac{1}{(\sigma^2)^3} \epsilon' \epsilon \right] = -\frac{T}{2(\sigma^2)^2} + \frac{1}{(\sigma^2)^3} E(\epsilon' \epsilon) = \frac{T}{2(\sigma^2)^2}$$

$$3) -E \left[\frac{\partial l}{\partial \beta \partial \sigma^2} \right] = +\frac{1}{(\sigma^2)^2} X' E(\epsilon) = 0$$

* La Matriz de Información de Fisher:

$$I_F(\beta, \sigma^2) = -E[H(\beta, \sigma^2)] = \begin{bmatrix} \frac{1}{\sigma^2} (X'X) & 0 \\ 0 & \frac{T}{2\sigma^4} \end{bmatrix}$$

\Rightarrow La varianza asintótica es la inversa de la matriz de información de Fisher.
$$Asor \begin{bmatrix} \hat{\beta}_{MV} \\ \hat{\sigma}_{MV}^2 \end{bmatrix} = [I_F(\beta, \sigma^2)]^{-1}$$

• Efecto aditivo de ser mujer sobre el ingreso: mide la diferencia de interceptos entre hombres y mujeres.


β_2 : Efecto multiplicativo de ser mujer sobre el ingreso: mide la diferencia de los efectos de las notas sobre los ingresos entre hombres y mujeres (pendientes).

4. Relevancia de Profesión:

$$\text{ingreso}_i = \beta_0 + \beta_1 \text{mujer}_i + \beta_2 \text{doctor}_i + \beta_3 \text{mujer}_i \text{doctor}_i + \epsilon_i$$

Interpretación:

- 1) $E[\text{ingreso} | \text{mujer}=1, \text{doctor}=1] = (\beta_0 + \beta_1) + (\beta_2 + \beta_3) \longrightarrow \text{mujer doctora}$
- 2) $E[\text{ingreso} | \text{mujer}=1, \text{doctor}=0] = (\beta_0 + \beta_1) \longrightarrow \text{mujer no doctora}$
- 3) $E[\text{ingreso} | \text{mujer}=0, \text{doctor}=1] = (\beta_0 + \beta_2) \longrightarrow \text{hombre doctor}$
- 4) $E[\text{ingreso} | \text{mujer}=0, \text{doctor}=0] = \beta_0 \longrightarrow \text{hombre no doctor.}$



Relevancia de genero

$$H_0: \beta_1 = \beta_3 = 0$$

Relevancia de profesión

$$H_0: \beta_2 = \beta_3 = 0$$

5. Relevancia genero, notas y profesión

$$\text{Ingreso}_i = \beta_0 + \beta_1 \text{mujer}_i + \beta_2 \text{doctor}_i + \beta_3 \text{notas}_i + \beta_4 \text{doc.muje.} + \beta_5 \text{not.mujer} + \beta_6 \text{not.doc}$$

Interpretación:

- 1) $E[\text{ingreso} | \text{mujer}=1, \text{doctor}=1, \text{notas}] = (\beta_0 + \beta_1 + \beta_2 + \beta_4) + (\beta_3 + \beta_5 + \beta_6) \text{notas}$
- 2) $E[\text{ingreso} | \text{mujer}=1, \text{doctora}=0, \text{notas}] = (\beta_0 + \beta_1) + (\beta_3 + \beta_5) \text{notas}$

6. i) $\text{ingreso}_i = \beta_0 + \beta_1 \text{mujer}_i + \beta_2 \text{doctor}_i + \beta_3 \text{abogado}_i + \beta_4 \text{profesor}_i + \beta_5 \text{notas}_i + \epsilon_i$
 \Rightarrow No se puede estimar el modelo por la trampa de las variables dummies
 Entonces, tenemos que eliminar una categoría (base).

ii) $\text{ingreso}_i = \beta_0 + \beta_1 \text{mujer}_i + \beta_2 \text{doctor}_i + \beta_3 \text{abogado}_i + \beta_4 \text{notas}_i + \epsilon_i$

Interpretación

1) $E[\text{ingreso} | \text{mujer}=1, \text{doctor}=1, \text{abogado}=0, \text{notas}] = (\beta_0 + \beta_1 + \beta_2) + \beta_4 \text{notas}$

2) $E[\text{ingreso} | \text{mujer}=0, \text{doctor}=1, \text{abogado}=0, \text{notas}] = (\beta_0 + \beta_2) + \beta_4 \text{notas}$

3) $E[\text{ingreso} | \text{mujer}=0, \text{doctor}=0, \text{abogado}=1, \text{notas}] = (\beta_0 + \beta_3) + \beta_4 \text{notas}$